



ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ
ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

Ψηφιακή Επεξεργασία Εικόνας
Εργασία 3: Image segmentation

Αφροδίτη Αβραμίδου, ΑΕΜ: 10329

Άνοιξη 2025

Ζητούμενο εργασίας:

Οι στόχοι της εργασίας είναι οι εξής: η αναπαράσταση των εικόνων εισόδου ως γράφους με χρήση του affinity matrix που περιγράφει μη-κατευθυντικό γράφο $G = (V, E)$ καθώς και η κατάτμηση εικόνας με τις μεθόδους spectral clustering και normalized cuts - αναδρομική και μη αναδρομική.

Αρχικά έχω υλοποιήσει την συνάρτηση **image_to_graph()** με την οποία η εικόνα εισόδου μετατρέπεται σε έναν γράφο ομοιότητας (affinity graph), δηλαδή έναν πίνακα που περιγράφει το πόσο κοντά ή παρόμοια είναι μεταξύ τους τα pixels της εικόνας βάσει του χρώματος. Στον γράφο αυτόν κάθε pixel είναι μια κορυφή (node). Κάθε ζεύγος pixels έχει ένα βάρος που εκφράζει το πόσο παρόμοια είναι και υπολογίζεται μέσω μιας αντίστροφης εκθετικής συνάρτησης της Ευκλείδειας απόστασης μεταξύ των pixels : $A(i, j) = \frac{1}{e^{d(i,j)}}$. Η συνάρτηση μου επιστρέφει τετραγωνικό (και συμμετρικό) πίνακα όπου $\text{affinity_mat}[i, j]$ είναι η ομοιότητα μεταξύ των pixel i και j .

Ακολουθεί η υλοποίηση της συνάρτησης **spectral_clustering()** δηλαδή κατάτμηση κόμβων ενός γράφου βασισμένη σε φασματικές ιδιότητες του Λαπλασιανού πίνακα L του γράφου: επίλυση του προβλήματος ιδιοτιμών $Lx = \lambda x$ κρατώντας τις k μικρότερες ιδιοτιμές και τα k ιδιοδιανύσματα που αντιστοιχούν στις ιδιοτιμές αυτές και εκτέλεση του αλγορίθμου k-means clustering πάνω στις γραμμές του πίνακα των ιδιοδιανυσμάτων, για εντοπισμό των clusters στις οποίες ανήκουν οι κορυφές του γράφου. Έτσι ως έξοδο της συνάρτησης παίρνω labels από 0 έως $k-1$ (όπου k ο αριθμός των clusters) για κάθε σημείο της εικόνας. Τα βήματα που ακολούθησα για την υλοποίηση είναι τα 5 που περιγράφονται στην αντίστοιχη ενότητα της εκφώνησης.

Ο έλεγχος λειτουργίας της παραπάνω συνάρτησης ελέγχεται στο **demo1**, με την χρήση ενός προ-κατασκευασμένου affinity matrix. στο οποίο . Τα αποτελέσματα που πήρα από αυτό είναι τα εξής:

--- Clustering με $k = 2$ ---

Ετικέτες clusters (πρώτα 20): [1 1 1 1 0 0 0 0 0 0 0]

Σύνολο μοναδικών ετικετών: [0 1]

--- Clustering με $k = 3$ ---

Ετικέτες clusters (πρώτα 20): [1 1 1 1 0 0 0 0 2 2 2]

Σύνολο μοναδικών ετικετών: [0 1 2]


--- Clustering με $k = 4$ ---

Ετικέτες clusters (πρώτα 20): [2 2 2 2 3 0 3 3 1 1 1]

Σύνολο μοναδικών ετικετών: [0 1 2 3]

Από τα αποτελέσματα αυτά μπορώ να συμπεράνω ότι ο αλγόριθμος spectral clustering δουλεύει σωστά και αποδίδει προοδευτικά πιο λεπτομερή διαχωρισμό με την αύξηση του k , δηλαδή τον αριθμό των clusters – περιοχών στις οποίες θέλω να ομαδοποιήσω τα δεδομένα. Το spectral clustering καταφέρνει να διαχωρίσει τα δεδομένα σε λογικά συμπαγείς ομάδες, ακόμα και με σχετικά μικρό affinity matrix (12x12). Έτσι βλέπω ότι η χρήση ιδιοδιανυσμάτων της Λαπλασιανής είναι ιδιαίτερα κατάλληλη για μη γραμμικά διαχωρίσιμα δεδομένα, σε αντίθεση με το απλό k -means σε ευκλείδεια χωρική αναπαράσταση. Τέλος παρατηρώ ότι τα labels αλλάζουν λογικά καθώς αυξάνω τα clusters, π.χ. τα τελευταία 4 σημεία (9–12) παραμένουν μαζί στο $k=2$, χωρίζονται στο $k=3$ και ακόμα πιο λεπτομερώς στο $k=4$.

Ακολουθεί το **demo2** με το οποίο ελέγχω την λειτουργία της `spectral_clustering()` σε συνδυασμό με την `image_to_graph()` χρησιμοποιώντας ως εικόνες αναφοράς τις d2a και d2b που μου δίνονται. Καθεμία από αυτές μετατρέπεται στον αντίστοιχο γράφο με την βοήθεια της `image_to_graph()` και στην συνέχεια εφαρμόζεται ο αλγόριθμος του spectral clustering, για πλήθος κέντρων $k = 2, 3, 4$. Τα αποτελέσματα που πήρα είναι τα εξής:



Παρατηρήσεις:

Η εικόνα d2a φαίνεται πως αποτελείται από αρκετά ξεκάθαρες και διαχωρίσιμες περιοχές. Για $k = 2$ το clustering αποδίδει πολύ καλά, εντοπίζοντας τις 2 ξεχωριστές χρωματικές περιοχές. Για $k=3$ εμφανίζεται μια επιπλέον ζώνη/περιοχή (στην αλλαγή χρώματος). Για $k = 4$ το clustering γίνεται πιο χασοτικό σε μερικά σημεία, ειδικά κοντά

στα όρια μεταξύ περιοχών. Εφόσον η εικόνα στην πραγματικότητα έχει μόνο 3 χρωματικές περιοχές, το spectral clustering αναγκάζεται να «εφεύρει» επιπλέον clusters, γεγονός που οδηγεί σε τεχνητό over-segmentation.

Όσον αφορά την εικόνα d2b, φαίνεται πως είναι μια πιο ρεαλιστική εικόνα, πιθανότατα με πιο σύνθετες δομές να εμφανίζονται σε αυτήν όπως επίσης και χρωματική ποικιλία. Για $k=2$, το clustering καταφέρνει να ξεχωρίσει τις πιο έντονες δομές στην εικόνα από το φόντο. Για $k = 3$ το segmentation βελτιώνεται, με πιο λεπτομερή διαχωρισμό σε αντικείμενα και φόντο, καθώς και περιγράμματα. Συγκεκριμένα βλέπω ότι καταφέρνει να διαχωρίσει τα χέρια (άσπρο χρώμα) , το καπέλο το πρόσωπο και τα παπούτσια (κόκκινο, μπεζ, καφέ) όπως επίσης και το κόκκινο πλαίσιο γύρω από τον χαρακτήρα του Super Mario. Τέλος για $k = 4$ έχω πιο λεπτομερή clusters, ωστόσο γεωμετρικά/χωρικά ασύνδετα σημεία του ίδιου χρώματος ανήκουν στο ίδιο cluster (π.χ. γωνίες, μεσαία σημεία), χωρίς να υπάρχει συνέχεια στην εικόνα.

Συμπεράσματα:

- Το Spectral Clustering αποδίδει πολύ καλά σε εικόνες με καθαρές περιοχές όπως η d2a, ειδικά όταν το k ανταποκρίνεται στο πραγματικό πλήθος περιοχών (3 στην προκειμένη περίπτωση).
- Σε πιο ρεαλιστικές ή πολύπλοκες εικόνες όπως η d2b αποδίδει μεν, αλλά είναι πιο ευαίσθητο σε θόρυβο, ειδικά για μεγαλύτερα k .
- Ο affinity matrix λειτουργεί σωστά για χρωματική ομοιότητα, αλλά δεν λαμβάνει υπόψη τη χωρική πληροφορία. Αυτός είναι και ο λόγος που εμφανίζονται αποσπασματικές περιοχές, ειδικά στη d2b με μεγάλο k . Αυτό συμβαίνει καθώς οι τιμές των βαρών των ακμών του γράφου θα υπολογίζονται ως $A(i, j) = \frac{1}{e^{d(i,j)}}$, όπου $d(i, j)$ η Ευκλείδεια απόσταση χρωματικής φωτεινότητας μεταξύ του i -οστού και του j -οστού pixel, εξαρτάται μόνο από το πόσο μοιάζουν τα χρώματά τους, ανεξαρτήτως θέσης τους στην εικόνα. Ως αποτέλεσμα ομαδοποιούνται στο ίδιο cluster pixels με παρόμοιο χρώμα αλλά που βρίσκονται ενδεχομένως μακριά μεταξύ τους. Έτσι για παράδειγμα η «δομή» του Mario (το σχήμα του σώματός του) δεν διατηρείται καλά, καθώς έχουμε μόνο χρωματική ομαδοποίηση.


Στην συνέχεια έχω υλοποιήσει τις 2 εκδοχές της μεθόδου Normalized-cuts, μη-αναδρομική και αναδρομική. Η συνάρτηση **n_cuts ()** υλοποιεί την πρώτη εκδοχή, η οποία είναι σχεδόν ίδια με αυτή της μεθόδου Spectral Clustering με την διαφορά ότι τώρα λύνουμε το γενικευμένο πρόβλημα ιδιοτιμών : $Lu=\lambda Du$ ανακτώντας τα k ιδιοδιανύσματα του Λαπλασιανού πίνακα που αντιστοιχούν στις μικρότερες ιδιοτιμές ("SM" = smallest magnitude).


Με την συνάρτηση **calculate_n_cut_value()** υπολογίζεται τη μετρική Normalized Cut (Ncut) για ένα δοσμένη διχοτόμηση ενός γράφου σε 2 clusters, βασισμένη στον affinity matrix. Πιο συγκεκριμένα, υπολογίζει πόσο καλή είναι η διάσπαση ενός

γράφου σε 2 ομάδες (A, B) και επιστρέφει μία τιμή `ncut` που όσο πιο μικρή είναι, τόσο καλύτερη η διαμέριση. Επιπλέον χρησιμοποιείται συχνά ως κριτήριο τερματισμού στην αναδρομική μέθοδο `n_cuts_recursive`.

Τέλος η 2^η εκδοχή της μεθόδου υλοποιείται με την συνάρτηση `n_cuts_recursive()` η οποία εφαρμόζει αναδρομικά την Normalized Cuts. Ξεκινάει με τον πλήρη γράφο και προσπαθεί να το χωρίσει σε 2 clusters, αν το split είναι καλό, βάσει της μετρικής `ncut_value` και τα δύο μέρη έχουν αρκετούς κόμβους, βάσει του T1, τότε συνεχίζει αναδρομικά να χωρίζει το κάθε cluster, αλλιώς τερματίζει την αναδρομή και επιστρέφει τα τελικά labels. Οι παράμετροι T1 και T2 λειτουργούν ως κριτήρια διακοπής για να αποφασιστεί αν θα συνεχιστεί η διαμέριση ενός cluster ή όχι. Ο T1 ορίζει το ελάχιστο επιτρεπτό μέγεθος (αριθμό κόμβων/pixels) που πρέπει να έχει κάθε νέο cluster για να θεωρηθεί έγκυρο και να συνεχίσει η αναδρομή. Αν ένα cluster έχει μέγεθος $\geq T1$ μπορεί να διαμεριστεί ξανά, ενώ αν μέγεθος $< T1$ θεωρείται πολύ μικρό για περαιτέρω split και σταματάει η αναδρομή. Αντίστοιχα ο T2 ορίζει το ανώτατο όριο αποδεκτής τιμής για το `ncut_value`, που μετράει την «ποιότητα» του split. Το `ncut_value` είναι χαμηλότερο για καλύτερα splits. Αν $ncut_value \leq T2$, το split είναι ποιοτικά καλό και συνεχίζουμε με αναδρομή, ενώ αν $ncut_value > T2$, το split είναι κακής ποιότητας και η αναδρομή σταματάει σε αυτό το σημείο.

Στο **demo3a** ελέγχεται η λειτουργία της συνάρτησης `n_cuts()` και τα αποτελέσματά της συγκρίνονται με αυτά της Spectral Clustering για τιμές $k=2,3,4$:






Παρατηρώ ότι η Normalized cuts (1^η σειρά της παραπάνω εικόνας) φαίνεται να κάνει καλύτερη δουλειά στην ομαδοποίηση σε σχέση με την Spectral Clustering που υλοποιήθηκε προηγουμένως (2^η σειρά της εικόνας). Η μέθοδος η_cuts επιδιώκει ρητά την ελαχιστοποίηση της μετρικής Normalized Cut, η οποία λαμβάνει υπόψη τόσο τη συνοχή εντός των ομάδων όσο και τη διαχωριστικότητα μεταξύ τους. Αντίθετα, η spectral clustering βασίζεται αποκλειστικά στα ιδιοδιανύσματα του Λαπλασιανού πίνακα, χωρίς να στοχεύει άμεσα στη βελτιστοποίηση της μετρικής Ncut.

Η η_cuts παράγει πιο καθαρές, συνεκτικές και νοηματικά εύστοχες περιοχές, ακόμη και για μικρές τιμές του k. Καθώς το k αυξάνεται η ποιότητα της spectral clustering βελτιώνεται, ωστόσο εξακολουθεί να παρουσιάζει μικρότερη συνέπεια σε σχέση με τη η_cuts, ιδιαίτερα στις άκρες των αντικειμένων και στις περιοχές χαμηλής συνάφειας. Συνολικά, τα πειραματικά αποτελέσματα επιβεβαιώνουν ότι η μέθοδος Normalized Cuts υπερέχει στην τμηματοποίηση εικόνων βάσει γράφων, ειδικά όταν στόχος είναι η μέγιστη συνοχή εντός των ομάδων και ο ελάχιστος συσχετισμός μεταξύ τους.

Ακολουθεί το **demo3b**, στο οποίο εκτελώ την αναδρομική μέθοδο n-cuts για ένα βήμα, δηλαδή σπάσιμο του αρχικό γράφου σε 2 κομμάτια. Για τις παραμέτρους T1 και T2 επέλεξα τις τιμές $T1 = -1$ και $T2 = 2$. Τα αποτελέσματά της συγκρίνονται και πάλι με αυτά της Spectral Clustering για $k=2$:



Unique labels: [0 1]

count_0: 1500, count_1: 1000 -> πλήθος pixel της 50x50 εικόνας μας που ανήκουν σε κάθε cluster

Ncut value: 0.5092-> το "κόστος" του διαχωρισμού της εικόνας- γράφου σε 2 clusters δηλαδή πόσο καλή ή κακή είναι η κατάτμηση που έγινε, η μετρική-έξοδος της calculate_n_cut_value()

Παρατηρώ ότι η μετρική Ncut = 0.5092 είναι αρκετά χαμηλή, υποδεικνύοντας ότι η διχοτόμηση που επιτεύχθηκε είναι ποιοτική, δηλαδή οι δύο ομάδες είναι καλά διαχωρισμένες με χαμηλή συνάφεια μεταξύ τους. Επίσης το εσωτερικό της κάθε ομάδας είναι ομοιογενές, αφού η ncut μετρά το σχετικό κόστος διαχωρισμού. Τέλος η κατανομή 1500–1000 pixels δείχνει έναν ισορροπημένο και ουσιαστικό διαχωρισμό. Έτσι συμπεραίνω ότι η μέθοδος n_cuts πέτυχε σαφή διαχωρισμό αντικειμένων από φόντο, υποδεικνύοντας την παρουσία ισχυρής δομής στην εικόνα d2a.



Unique labels: [0. 1.]



count_0: 1361, count_1: 1139

Ncut value: 0.7853

Παρατηρώ ότι η τιμή $N_{cut} = 0.7853$ είναι υψηλότερη από την προηγούμενη εικόνα, γεγονός που σημαίνει ότι ο διαχωρισμός είναι λιγότερο «καθαρός» δηλαδή υπάρχει μεγαλύτερη συνάφεια μεταξύ των δύο ομάδων γεγονός λογικό καθώς η εικόνα d2b περιέχει περισσότερες ενδιάμεσες ή δυσδιάκριτες περιοχές, όπου η μέθοδος έχει δυσκολευτεί να εντοπίσει σαφή σύνορα. Παρόλα αυτά, η τιμή παραμένει κάτω του ορίου $T_2 = 2$, άρα η διαμέριση είναι αποδεκτή.

Συγκρίνοντας παρατηρώ ότι στην περίπτωση που $k=2$, η n-cuts διαχώρισε αποτελεσματικά το κυρίως αντικείμενο από το φόντο, ενώ η spectral clustering οδήγησε σε ασταθή τμηματοποίηση, με μικρές αποσπασματικές ομάδες και θόρυβο.

Τέλος στο **demo3c** παρουσιάζεται η ολοκληρωμένη εκτέλεση της μεθόδου ncuts για κατώφλια $T_1=$ και $T_2=0.2$. και συγκρίνονται τα αποτελέσματα της ολοκληρωμένης διαδικασίας ncuts πάνω στην κάθε εικόνα εισόδου. Συγκρίνονται τα αποτελέσματα της αναδρομικής μεθόδου ncuts σε σχέση με τα αποτελέσματα που προκύπτουν από την διαδικασία spectral clustering και τα αποτελέσματα της μη-αναδρομικής μεθόδου ncuts για $k = 2$ και $k = 3$:



Παρατηρήσεις για την εικόνα d2a:

Recursive Ncuts ($T_1=5$, $T_2=0.20$): επέστρεψε 2 ετικέτες, χωρίζοντας κυρίως την εικόνα σε 2 ζώνες. Οι κόκκινη και πράσινη περιοχές ενώθηκαν, ενώ η μπλε απομονώθηκε, άρα η μέθοδος δεν "είδε" τα 3 χρώματα ως ξεχωριστά.

Ncuts ($k=2$ και $k=3$): με $k=2$ βλέπουμε αντίστοιχο διαχωρισμό με την recursive: οι δύο αριστερές περιοχές ξεχωρίζουν από την δεξιά. Με $k=3$, η εικόνα διαχωρίζεται πολύ σωστά στις κόκκινη, πράσινη και μπλε περιοχές, απεικονίζοντας με ακρίβεια την πραγματικότητα.

Spectral Clustering ($k=2$ και $k=3$): συμπεριφέρεται πολύ παρόμοια με την Ncuts: με $k=2$ έχουμε τον ίδιο διμερή διαχωρισμό, ενώ με $k=3$, επιτυγχάνεται τέλεια ομαδοποίηση των 3 χρωμάτων, παρόμοια με την $n_cuts(k=3)$.

Συμπερασματικά, η n_cuts και το spectral clustering με $k=3$ αποδίδουν πολύ καλύτερα σε αυτή την περίπτωση, καθώς εντοπίζουν και τις 3 χρωματικές ζώνες. Η αναδρομική n_cuts δεν έχει «πείσει» για περαιτέρω διαχωρισμό, πιθανώς επειδή η μετρική Ncut για την υποδιάσπαση δεν έπεσε κάτω από το όριο T_2 .

Παρατηρήσεις για την εικόνα d2b:

Recursive Ncuts ($T_1=5$, $T_2=0.20$): επέστρεψε 2 ομάδες, όπου φαίνεται να διαχωρίζει τον Mario από το φόντο με σχετική επιτυχία. Οι περιοχές με τον Mario συγκεντρώνονται σε μία ομάδα. Η ομαδοποίηση είναι αρκετά καθαρή, χωρίς να γίνεται υπερ-διαμερισμός.

Ncuts ($k=2$ και $k=3$): Με $k=2$ το segmentation είναι παρόμοιο με το recursive, με ίσως λίγο πιο καθαρή διάκριση μεταξύ του Mario και του φόντου. Με $k=3$ εμφανίζονται περισσότερες λεπτομέρειες: ξεχωρίζουν επιμέρους μέλη (π.χ. σώμα, καπέλο).

Spectral Clustering ($k=2$ και $k=3$): Με $k=2$, δείχνει πολύ πιο «διάσπαρτο» αποτέλεσμα — μικρές απομονωμένες κουκίδες που δεν αντιστοιχούν σε οπτικά συνεκτικές περιοχές ενώ με $k=3$, η εικόνα βελτιώνεται, αλλά παραμένει κάπως θορυβώδης και κατακερματισμένη.

Συμπερασματικά, η αναδρομική Ncuts λειτουργεί πολύ ικανοποιητικά σε αυτή την περίπτωση καθώς καταφέρνει να πετύχει καθαρό διαχωρισμό Mario και φόντου, χωρίς να απαιτεί εκ των προτέρων τον αριθμό των clusters. Η Ncuts με $k=3$ προσθέτει λεπτομέρεια, ενώ η spectral clustering έχει τη χειρότερη συμπεριφορά, ειδικά με $k=2$ — πιθανόν λόγω του ότι δεν αξιοποιεί τόσο αποτελεσματικά τη γραφική δομή (δεν βασίζεται σε n_cut criterion).